

Da Matemática à Visão Computacional: Trajetória Acadêmica e Aplicações Estatísticas na Visão Computacional

Fernando Humberto de Almeida Moraes Neto

8 de novembro de 2024

Sumário

- 1 Introdução
- 2 Trajetória acadêmica
- 3 Visão Computacional
- 4 Redes Neurais Convolucionais
 - Aplicações
- 5 Yolo
 - Aplicações
- 6 Outras Aplicações
- 7 Considerações Finais

Introdução

- Professor Substituto do Departamento de Estatística.
- Bolsa de pesquisa FAPESB.
- Doutorando em Estatística.

Introdução

- Apresentar minha formação acadêmica e os projetos em que participei.
- Introduzir conceitos de Visão Computacional.
- A matemática e a estatística se tornaram essenciais para avanços tecnológicos que afetam nosso dia a dia.

Sumário

1 Introdução

2 Trajetória acadêmica

3 Visão Computacional

4 Redes Neurais Convolucionais

 ■ Aplicações

5 Yolo

 ■ Aplicações

6 Outras Aplicações

7 Considerações Finais

Formação Acadêmica

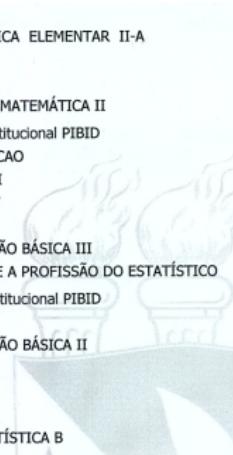
- **Graduação (2013-2017):** Licenciatura em Matemática - UFBA
 - Laboratório de Ensino de Matemática e Estatística (LEMA) - UFBA
 - Bolsista no Programa de Iniciação à Docência (PIBID) e Iniciação Científica (PIBIC)
- **Mestrado (2018-2020):** Matemática com concentração em Estatística - UFBA
 - FAPESB.
- **Doutorado (2020-atual):** Estatística - USP/UFSCar
 - CAPES.

Formação Acadêmica

2014-2	Aluno Bolsista do Programa Institucional PIBID EDCA02 ORGANIZAÇÃO DA EDUCAÇÃO BRASILEIRA II EDCA04 SOCIEDADE E EDUCAÇÃO EDCA82 ESTÁGIO SUPERVISIONADO II FIS121 FÍSICA GERAL E EXPERIMENTAL I-E MATB32 INTRODUÇÃO À TEORIA DOS NÚMEROS MATB59 ESTATÍSTICA BÁSICA A
2015-1	Aluno Bolsista do Programa Institucional PIBID ARQ013 DESCRIPTIVA I A * EDCA80 METODOLOGIA DO ENSINO DA MATEMÁTICA LETE46 LIBRAS-LÍNGUA BRASILEIRA DE SINAIS MAT198 FUNDAMENTOS DE MATEMÁTICA ELEMENTAR I-A MATB38 ÁLGEBRA LINEAR I- B MATB43 CÁLCULO DIFERENCIAL VETORIAL MATD41 INTRODUÇÃO AOS MODELOS LINEARES
2015-2	Aluno Bolsista do Programa Institucional PIBID FIS121 FÍSICA GERAL E EXPERIMENTAL I-E MATB35 GRUPOS E ANÉIS I MATB39 MATEMÁTICA PARA A EDUCAÇÃO BÁSICA I MATB40 SEQUÊNCIAS, SÉRIES E EDO MATB41 ÁLGEBRA LINEAR II-B MATB47 LABORATÓRIO DE ENSINO DE MATEMÁTICA I MATD40 ANALISE DE DADOS
2016-1	Aluno Bolsista do Programa Institucional PIBID BIO138 BIOMETRIA BASICA FIS122 FÍSICA GERAL E EXPERIMENTAL II-E

Formação Acadêmica

2016-1	MAT174 CÁLCULO NUMÉRICO I MAT199 FUNDAMENTOS DE MATEMÁTICA ELEMENTAR II-A MAT223 PROBABILIDADE I MATB46 FUNÇÕES HOLOMORFAS MATB48 LABORATÓRIO DE ENSINO DE MATEMÁTICA II
2016-2	Aluno Bolsista do Programa Institucional PIBID ADM001 INTRODUCÃO À ADMINISTRAÇÃO EDCA83 ESTÁGIO SUPERVISIONADO III EDCA84 ESTÁGIO SUPERVISIONADO IV MAT224 PROBABILIDADE II MATB45 MATEMÁTICA PARA A EDUCAÇÃO BÁSICA III MATD45 SISTEMAS DE INFORMAÇÕES E A PROFISSÃO DO ESTATÍSTICO
2017-1	Aluno Bolsista do Programa Institucional PIBID EDCA81 ESTÁGIO SUPERVISIONADO I MATB42 MATEMÁTICA PARA A EDUCAÇÃO BÁSICA II MATB44 ANÁLISE I MATB49 SEMINÁRIOS TEMÁTICOS MATD42 INFERENCE A MATE56 TÓPICOS ESPECIAIS EM ESTATÍSTICA B



PIBID

- Importância da monitoria no ensino fundamental - SEMENTE. 2015.
- Utilização do Triminó no ensino da Matemática - ENALIC. 2016.
- O Ensino da Matemática através de jogos - SEMENTE. 2016.

PIBID

- Uma Redescoberta da aritmética e dos números naturais - SEMENTE. 2016.
- O PIBID como Ferramenta de Colaboração no Ensino de Matemática no Colégio Estadual Henrique M. Catharino - SIMPÓSIO PIBID - UFBA. 2016.
- Estudo de preço de livros em Salvador - Congresso UFBA 70 Anos. 2016.

PIBIC

Análise de Sobrevida.

- Identificar os fatores de risco para o desligamento de funcionários nas empresas da Bahia.
- VI Encontro Baiano de Estatística.



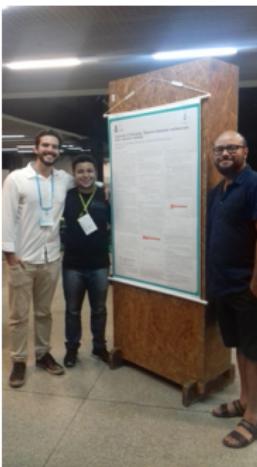
Detalhes da Formação

Mestrado

- Fundação de Amparo à Pesquisa do Estado da Bahia - FAPESB.
- Redes Neurais Convolucionais - CNN's para predição de câncer em dados de radiografias.



Mestrado



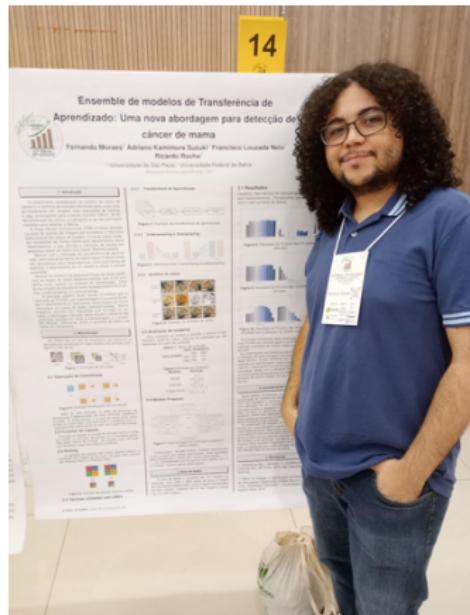
- Prediction of cadastral fraud of smokers in health plans.
- Cross-over of Bootstrap: Reduced Optimism method and other validation methods - Conference on Statistics and Data =
- Redes Neurais Convolucionais, Variantes e suas Aplicações - LED-DATE e o VII Encontro da Pós-Graduação em Matemática da UFBA. 2019.

Detalhes da Formação

Doutorado

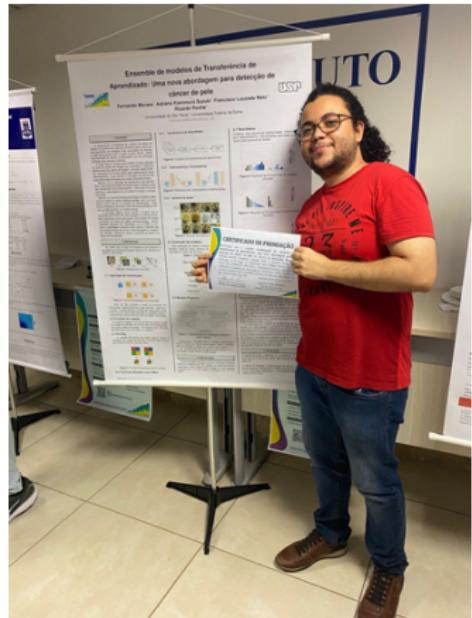
- Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES).
- Proposta de nova abordagem para melhorar o desempenho de CNNs em bases desbalanceadas.

Doutorado



- Ensemble de modelos de Transferência de Aprendizado: Uma nova abordagem para detecção de câncer de mama - 67º RBRas e no 20º SEAGRO. 2023.

Doutorado



- Ensemble de modelos de Transfência de Aprendizado: Uma nova abordagem para detecção de câncer de pele - 1st SaLLy Day. 2023.

Sumário

- 1 Introdução
- 2 Trajetória acadêmica
- 3 Visão Computacional
- 4 Redes Neurais Convolucionais
 - Aplicações
- 5 Yolo
 - Aplicações
- 6 Outras Aplicações
- 7 Considerações Finais

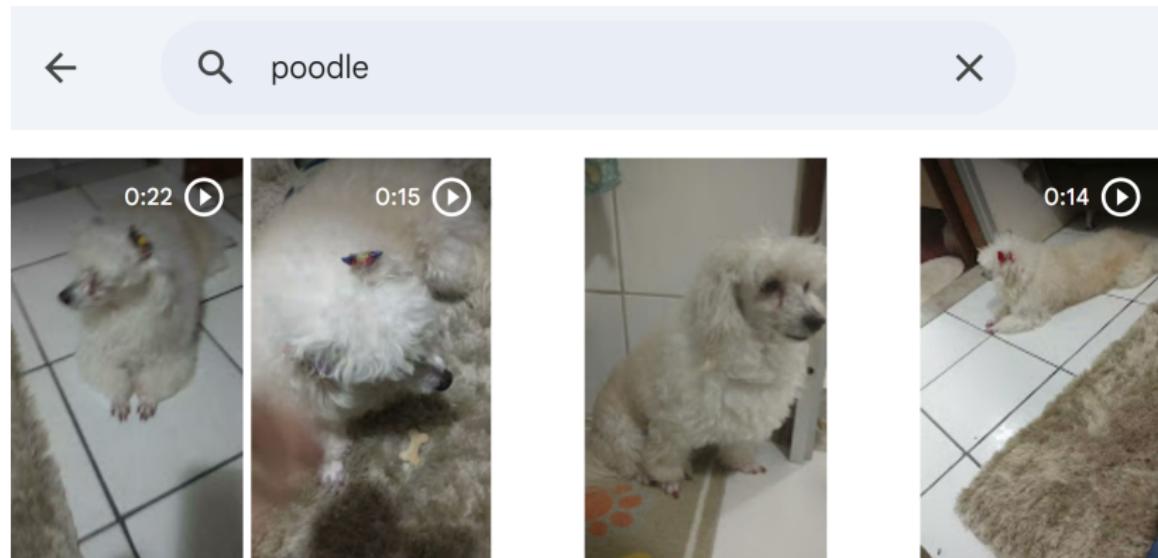
O que é Visão Computacional?

- Campo interdisciplinar que permite que máquinas interpretem imagens.
- Combina matemática, estatística e ciência da computação.
- Aplicações: identificação de objetos, diagnóstico médico, controle de qualidade.

O que é Visão Computacional?

- Esse modelo está funcionando no seu bolso neste momento.
 - Reconhecimento Facial;
 - Detecção de Objetos em Fotos e Vídeos;
 - Reconhecimento de Texto (OCR).

O que é Visão Computacional?



Como um computador reconhece imagens

- Atribuição de valores aos pixels conforme a sua intensidade de cor.

Como um computador reconhece imagens

a

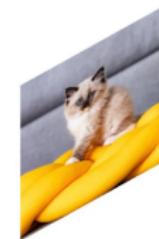
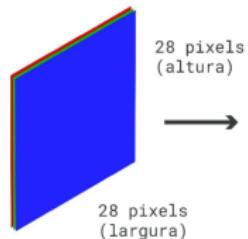
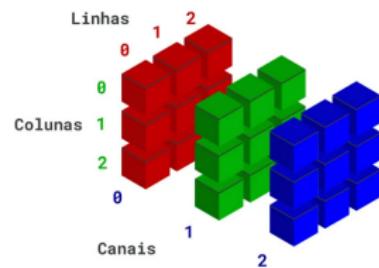


IMAGEM COLORIDA
(RGB)



28 pixels
(altura)

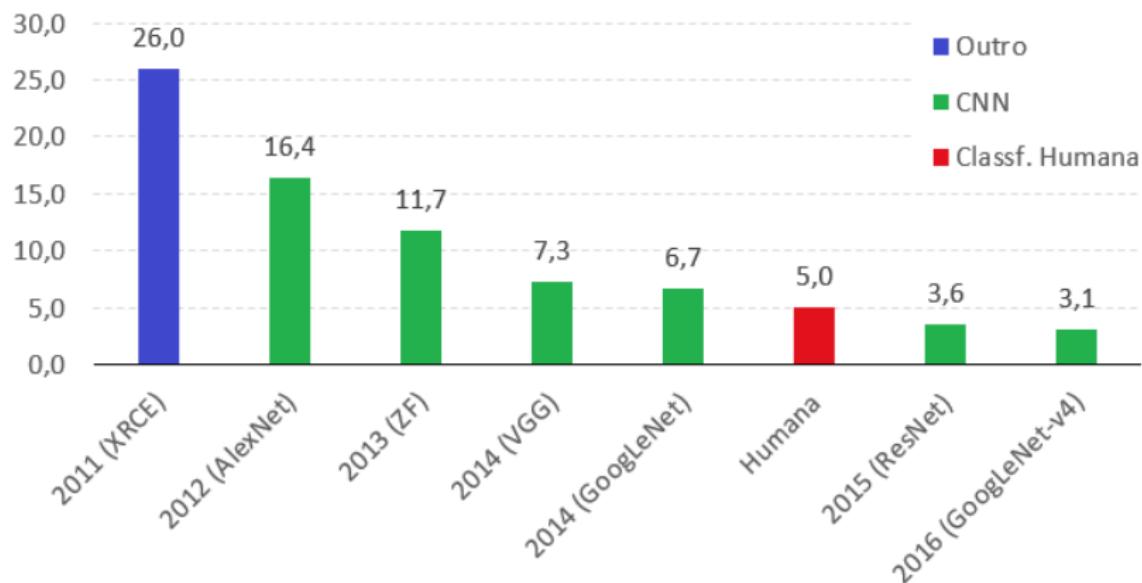
3 CANAIS
(RGB)



Como um computador reconhece imagens

Como um computador reconhece imagens

Classificação do top erro do ImageNet



Sumário

- 1 Introdução
- 2 Trajetória acadêmica
- 3 Visão Computacional
- 4 Redes Neurais Convolucionais
 - Aplicações
- 5 Yolo
 - Aplicações
- 6 Outras Aplicações
- 7 Considerações Finais

Introdução as CNN's

- Um tipo de arquitetura de aprendizado profundo que possui a operação de convolução em pelo menos uma camada.
- Essas redes são modeladas para processar dados em formato de múltiplos vetores.

Introdução as CNN's

- Um tipo de arquitetura de aprendizado profundo que possui a operação de convolução em pelo menos uma camada.
- Essas redes são modeladas para processar dados em formato de múltiplos vetores.

Introdução as CNN's

- Capacidade da mesma extrair características relevantes através dos *kernels* e depender do menor número de parâmetros de ajustes do que as redes totalmente conectadas com o mesmo número de camadas ocultas.

Arquitetura das CNN's

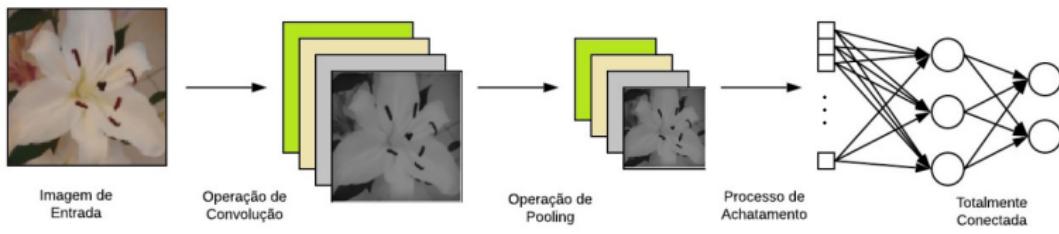


Figura 1: Exemplo de uma arquitetura geral de uma CNN.

Operação de Convolução

- As saídas do processo de convolução são organizadas em mapas de recursos e estão conectadas a uma parte da camada anterior por meio dos filtros.

Padding e o stride

- O *stride* (ou tamanho do passo) denota o número de *pixels* pelos quais o filtro se move após cada operação.
- O *padding* insere simetricamente novos pixels ao redor da imagem de entrada.

Operação de Convolução

- As saídas do processo de convolução são organizadas em mapas de recursos e estão conectadas a uma parte da camada anterior por meio dos filtros.

Padding e o stride

- O *stride* (ou tamanho do passo) denota o número de *pixels* pelos quais o filtro se move após cada operação.
- O *padding* insere simetricamente novos pixels ao redor da imagem de entrada.

Operação de Convolução

- As saídas do processo de convolução são organizadas em mapas de recursos e estão conectadas a uma parte da camada anterior por meio dos filtros.

Padding e o stride

- O *stride* (ou tamanho do passo) denota o número de *pixels* pelos quais o filtro se move após cada operação.
- O *padding* insere simetricamente novos pixels ao redor da imagem de entrada.

Convolução

- Considerando um *kernel/filtro* de tamanho bidimensional K e uma imagem de entrada X pode ser descrito por:

$$S(i, j) = (K * X)(i, j) = \sum_m \sum_n X(m, n)K(i - m, j - n).$$

Convolução

- Considerando um *kernel/filtro* de tamanho bidimensional K e uma imagem de entrada X pode ser descrito por:

$$S(i, j) = (K * X)(i, j) = \sum_m \sum_n X(m, n)K(i - m, j - n).$$

Operação de Convolução

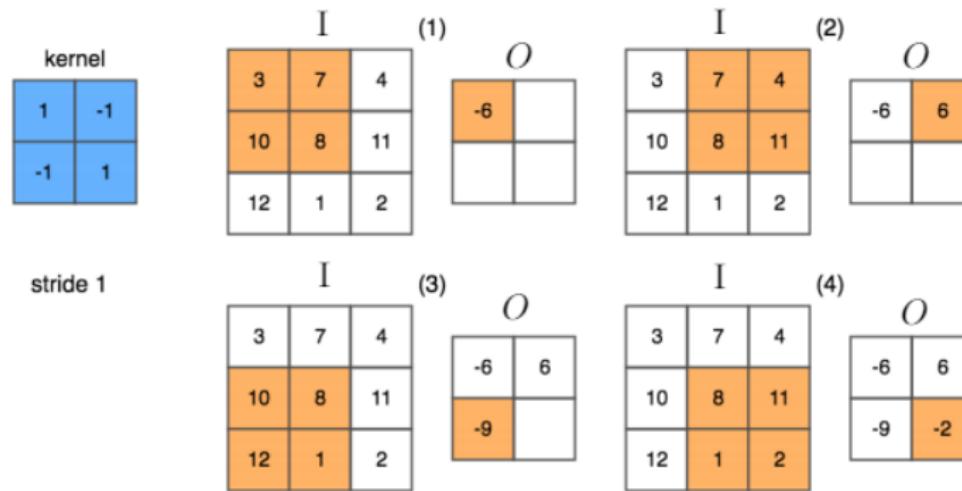


Figura 2: Processo de convolução.

Operação de Convolução

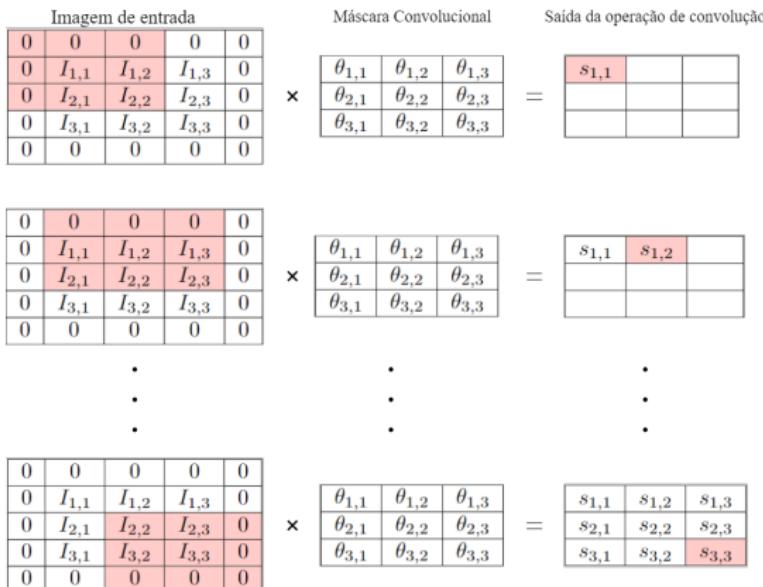


Figura 3: Processo de convolução.

Operação de Convolução

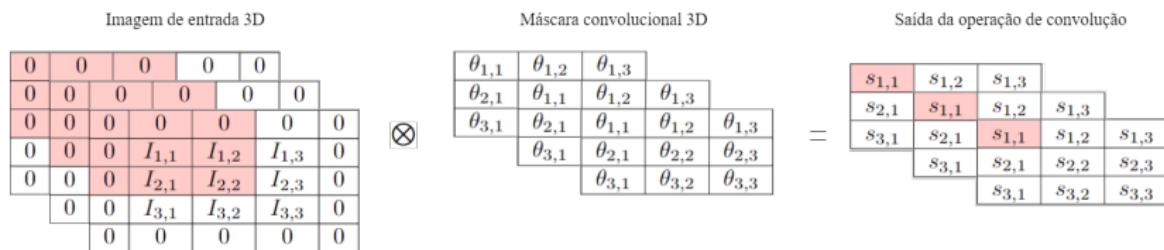


Figura 4: Processo de convolução 3d.

Pooling

- Reduzir a resolução dos mapas de recursos.

- Os tipos mais comuns são:
 - *pooling* máximo.
 - *pooling* médio.

Pooling

- Reduzir a resolução dos mapas de recursos.

- Os tipos mais comuns são:

- *pooling* máximo.
 - *pooling* médio.

Pooling

- Reduzir a resolução dos mapas de recursos.

- Os tipos mais comuns são:
 - *pooling* máximo.
 - *pooling* médio.

Pooling

- Reduzir a resolução dos mapas de recursos.

- Os tipos mais comuns são:
 - *pooling* máximo.
 - *pooling* médio.

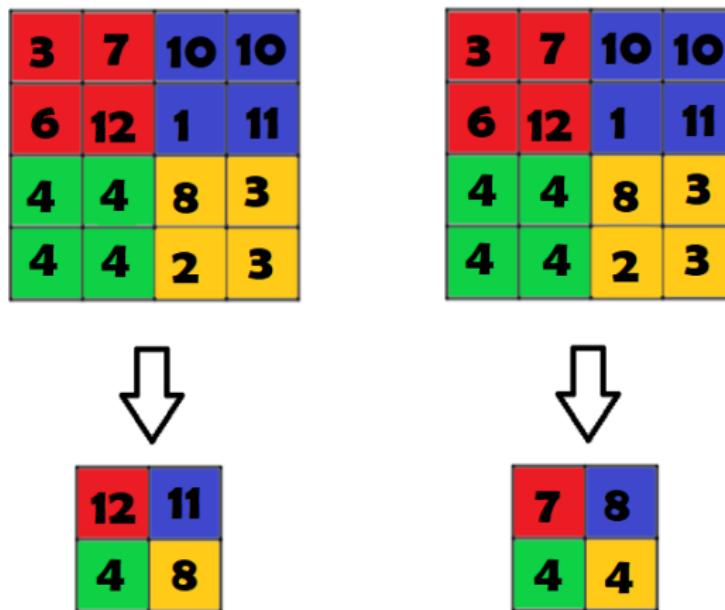


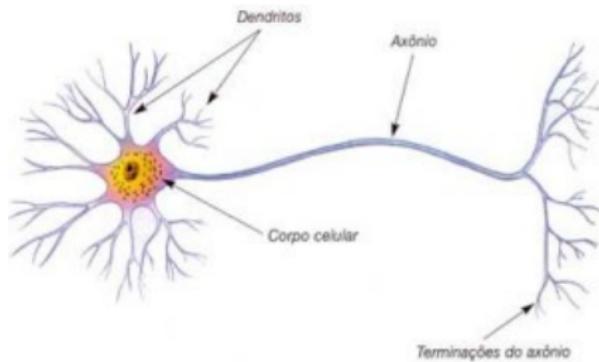
Figura 5: Exemplo de *pooling* máximo e médio.

Achatamento

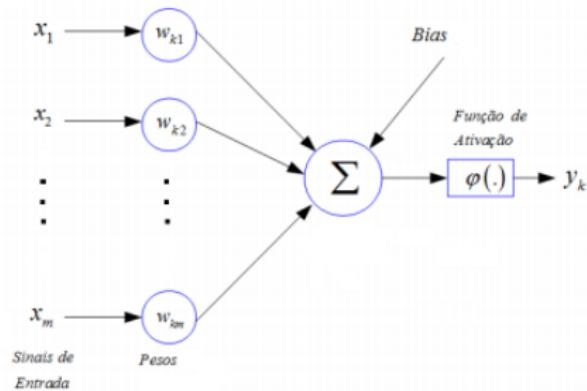
- Leva as características extraídas da imagem a uma rede neural artificial, na qual todas as suas unidades estão totalmente conectadas com a camada anterior.

Redes Neurais Artificiais

- O desenvolvimento das Redes Neurais Artificiais começou motivado por um desejo de tentar entender e imitar o cérebro humano.



Redes Neurais Artificiais



$$y_k = \varphi \left(\sum_{i=1}^m x_i w_i + b \right)$$

Brain Tumor MRI

- Hospedada na plataforma kaggle.

- Contém 253 imagens de ressonância magnética do cérebro, sendo 155 imagens que contém tumor e 98 não possuem.

Brain Tumor MRI

- Hospedada na plataforma kaggle.
- Contém 253 imagens de ressonância magnética do cérebro, sendo 155 imagens que contém tumor e 98 não possuem.

Imagens da base de dados Brain Tumor MRI

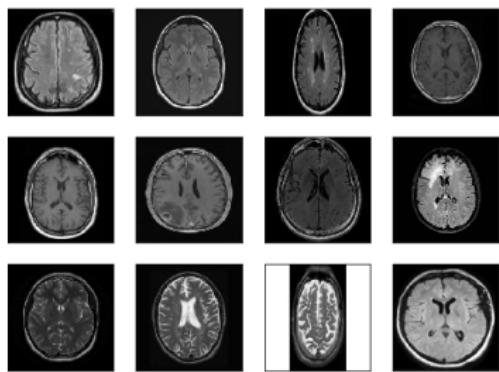


Figura 6: Imagens da base de dados sem tumor.

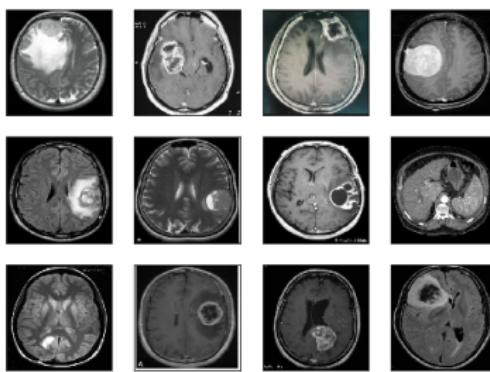


Figura 7: Imagens da base de dados com tumor.

Pré-processamento

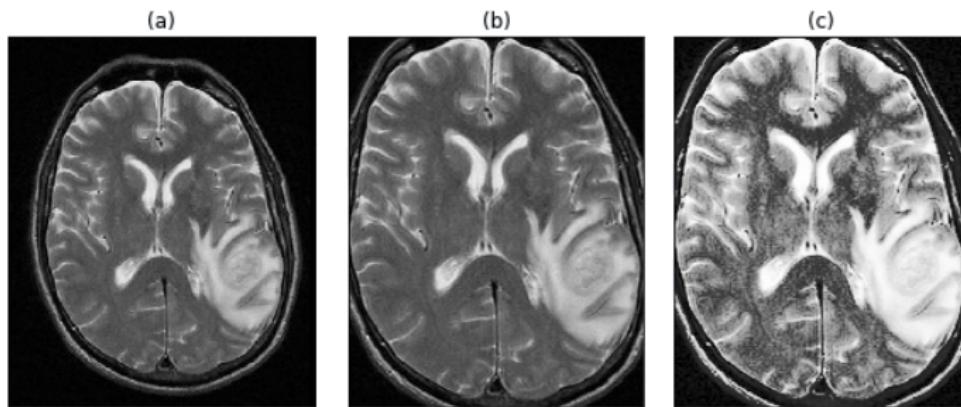


Figura 8: Pré-processamento, onde (a) é a imagem original, (b) é a imagem original cortada e (c) é a imagem final através da equalização do histograma.

Arquitetura da CNN utilizada

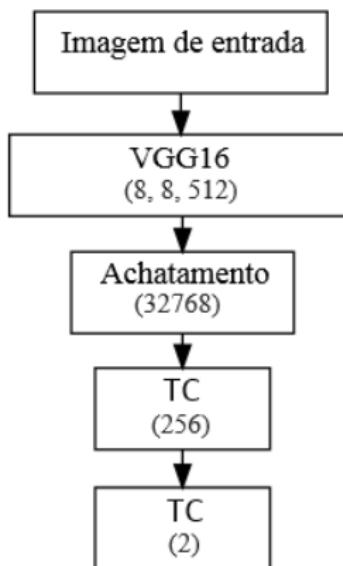


Figura 9: Esqueleto da CNN elaborada com suas respectivas dimensões de saída.

Resultados

Tabela 1: Matriz de confusão do modelo proposto.

Valor Preditivo	Valor Verdadeiro	
	Sem tumor	Com tumor
Sem tumor	8	1
Com tumor	2	27

Aplicativo



ACCamargo

- Disponibilizada pelo ACCamargo que é um hospital oncológico especializado no diagnóstico, tratamento e pesquisa de câncer.
- 161 imagens de resolução entre 3400 a 4800 *pixels* de altura e largura.
- 34 imagens com câncer maligno e 127 benigno.

ACCamargo

- Disponibilizada pelo ACCamargo que é um hospital oncológico especializado no diagnóstico, tratamento e pesquisa de câncer.
- 161 imagens de resolução entre 3400 a 4800 *pixels* de altura e largura.
- 34 imagens com câncer maligno e 127 benigno.

ACCamargo

- Disponibilizada pelo ACCamargo que é um hospital oncológico especializado no diagnóstico, tratamento e pesquisa de câncer.
- 161 imagens de resolução entre 3400 a 4800 *pixels* de altura e largura.
- 34 imagens com câncer maligno e 127 benigno.

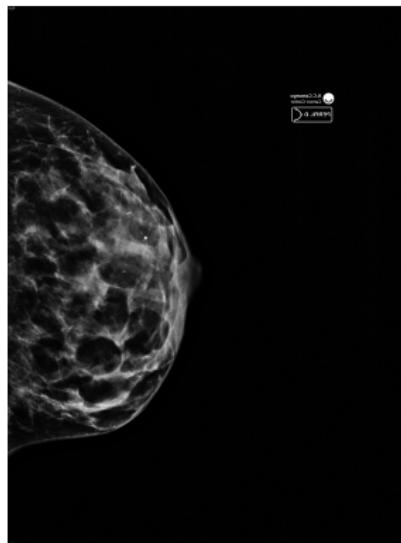


Figura 10: Imagem de uma das mamografias da base de dados.

Pré processamento

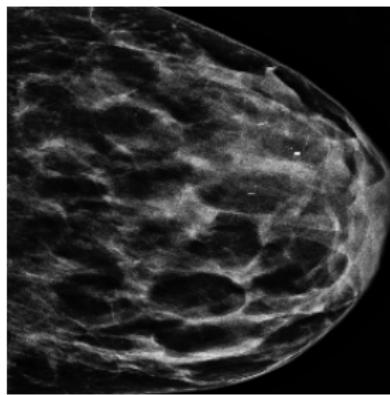


Figura 11: Imagem da base de dados com o corte aplicado.

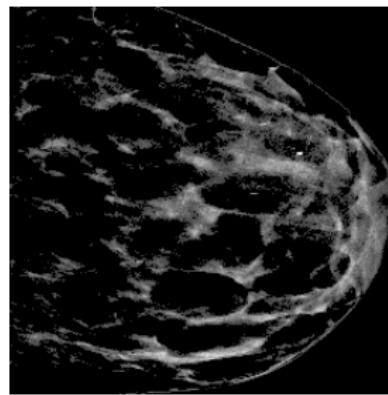


Figura 12: Imagem da base de dados com o filtro aplicado.

Modelos utilizados

- Foram construídos 15 modelos de transferência de aprendizado.

Resultados

Tabela 2: Matriz de confusão da combinação utilizada.

Valor Preditivo	Valor Verdadeiro	
	Benigno	Maligno
Benigno	244	38
Maligno	8	10

Sumário

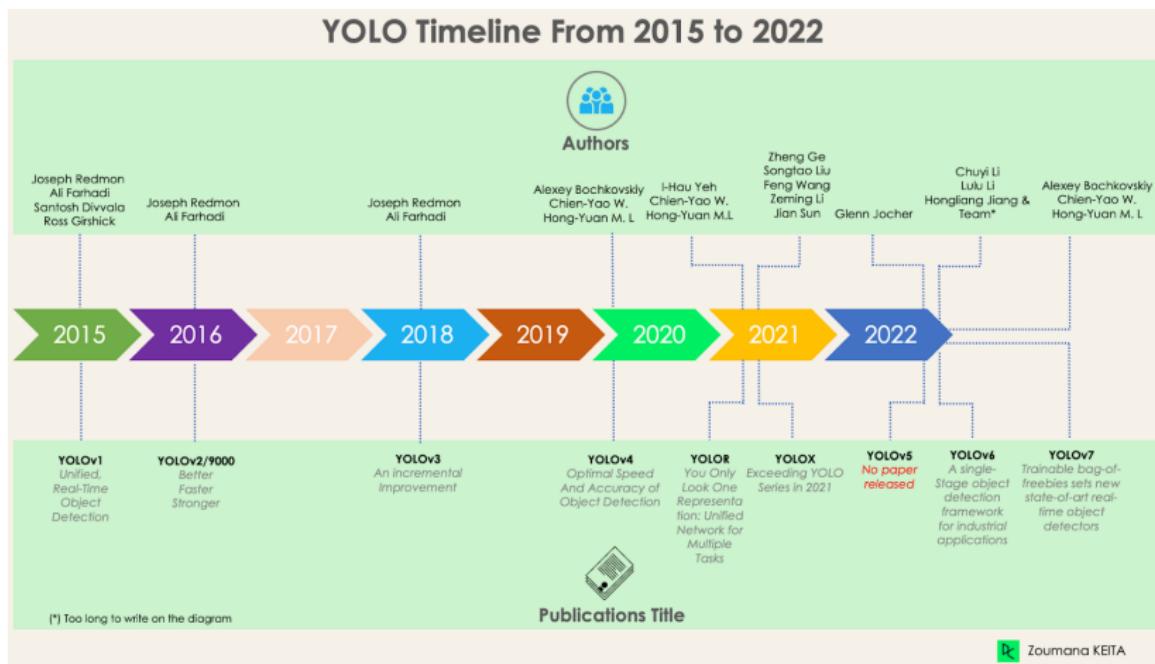
- 1 Introdução
- 2 Trajetória acadêmica
- 3 Visão Computacional
- 4 Redes Neurais Convolucionais
 - Aplicações
- 5 Yolo
 - Aplicações
- 6 Outras Aplicações
- 7 Considerações Finais

YOLO (You Only Look Once)

Introdução

- Detecção de objetos em tempo real.
- Processa a imagem inteira de uma só vez.

YOLO (You Only Look Once)



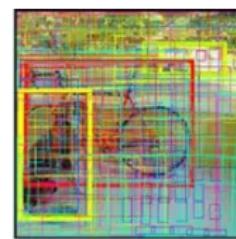
YOLO (You Only Look Once)



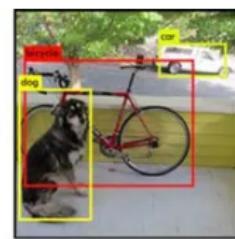
1) grid de 13x13



2) quanto maior a confiança, mais grossa é a linha representada



3) é feito a previsão da classe para cada caixa delimitadora



4) apenas são mantidas as caixas acima do limiar definido

Detecção de problemas em telhados



Introdução

- Proteção estrutural contra deterioração ambiental.
- Risco de acidentes e possibilidade de erros.

Introdução

- Proteção estrutural contra deterioração ambiental.
- Risco de acidentes e possibilidade de erros.

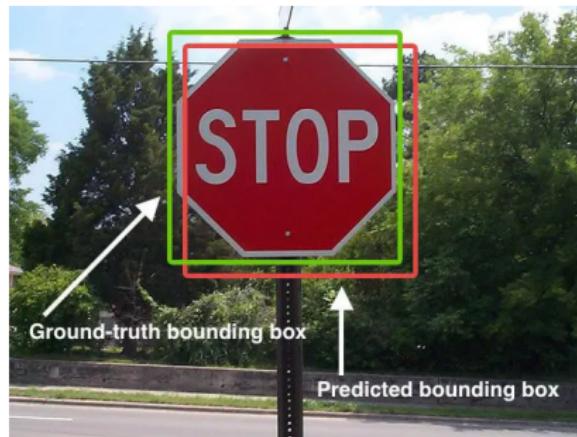
Detecção de problemas em telhados

- Inspeções tradicionais são demoradas, caras, imprecisas e inseguras.
- Uso de drones apoia o processo de aquisição de imagens.
- Análise manual das imagens apresenta subjetividade, lentidão e imprecisão.
- Sistema automatizado usando YOLO11 para detectar danos em telhados, facilitando a manutenção preventiva com uma interface em Streamlit.

Metodologia

- Identificação de anomalias, como rachaduras e integridade estrutural.
- Utilização de métricas como Precisão, Recall, IoU e mAP para avaliar a performance do modelo.

Intersection over Union (IoU)



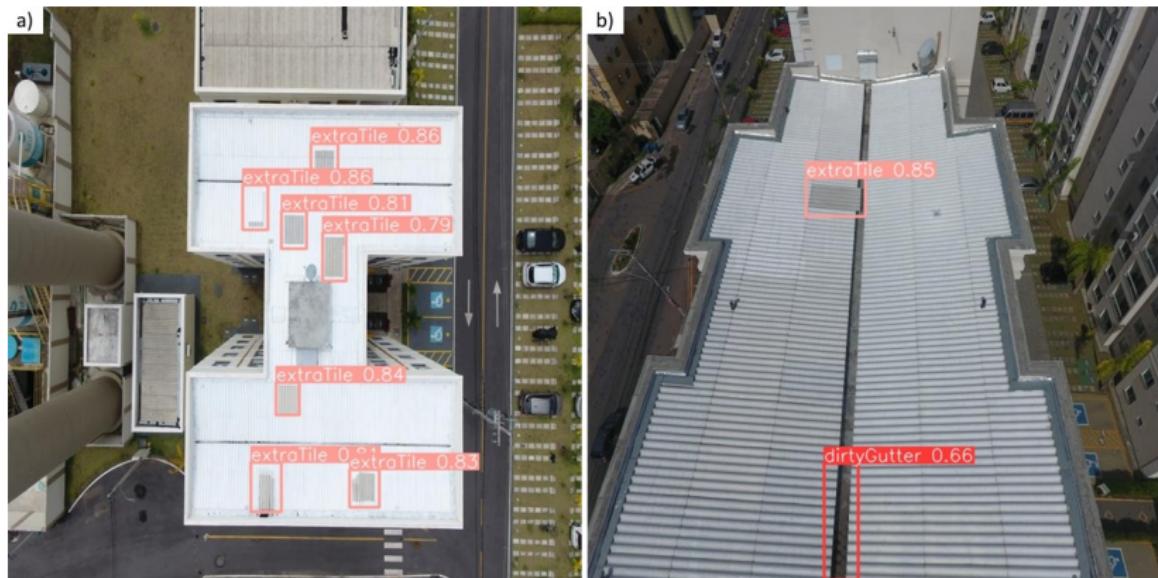
Base de Dados

- **Origem:** GETEC-UFBA.
- **Características:** 167 telhados inspecionados com drones.
- **Anotações de Imagens:** 1333 imagens anotadas para detecção de anomalias como telhas extras, oxidação em calhas, e alçapões abertos.

Base de Dados



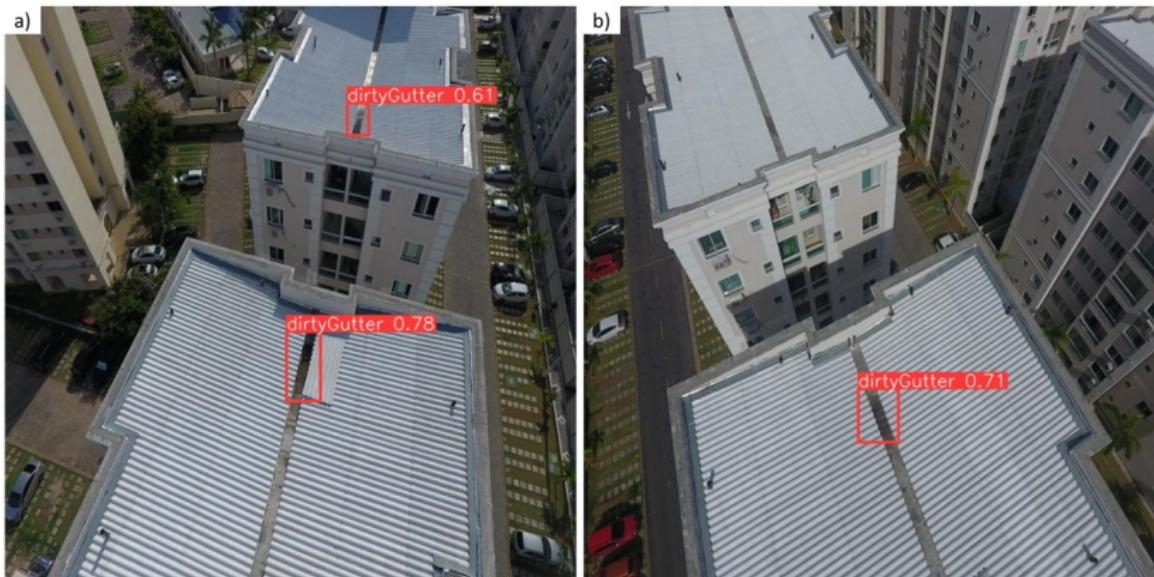
Resultados



Resultados



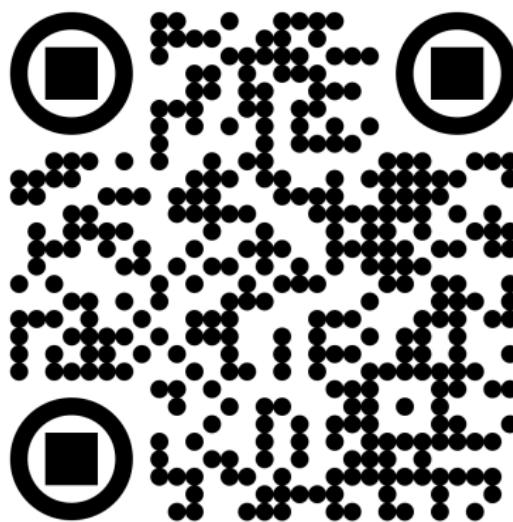
Resultados



Aplicativo Streamlit

- **Objetivo:** Facilitar a manutenção preventiva com interface acessível.
- **Exemplo de Uso:**

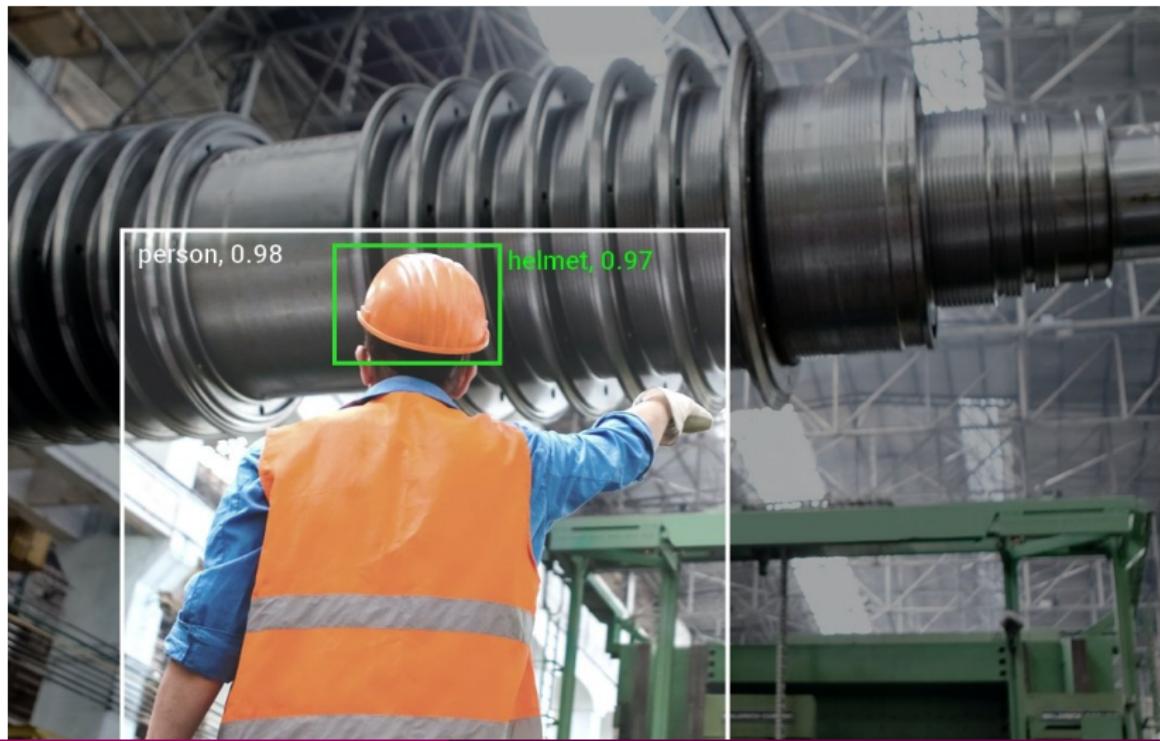
Aplicativo Streamlit



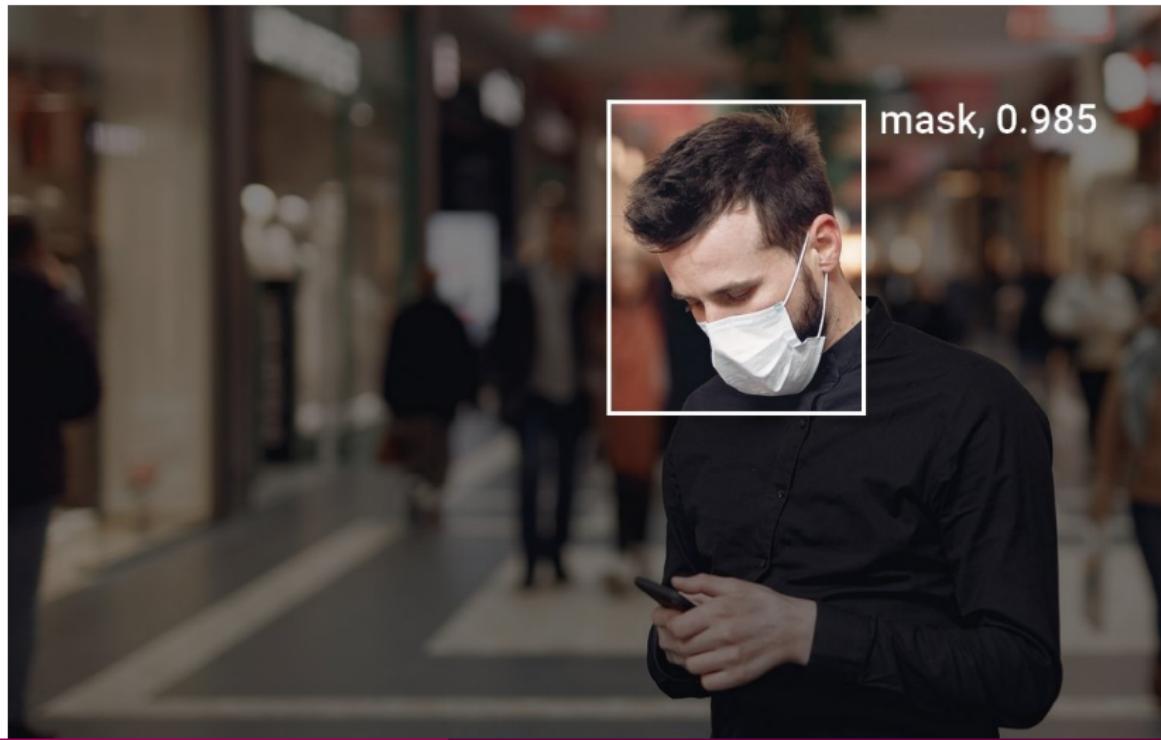
Sumário

- 1 Introdução
- 2 Trajetória acadêmica
- 3 Visão Computacional
- 4 Redes Neurais Convolucionais
 - Aplicações
- 5 Yolo
 - Aplicações
- 6 Outras Aplicações
- 7 Considerações Finais

Aplicações



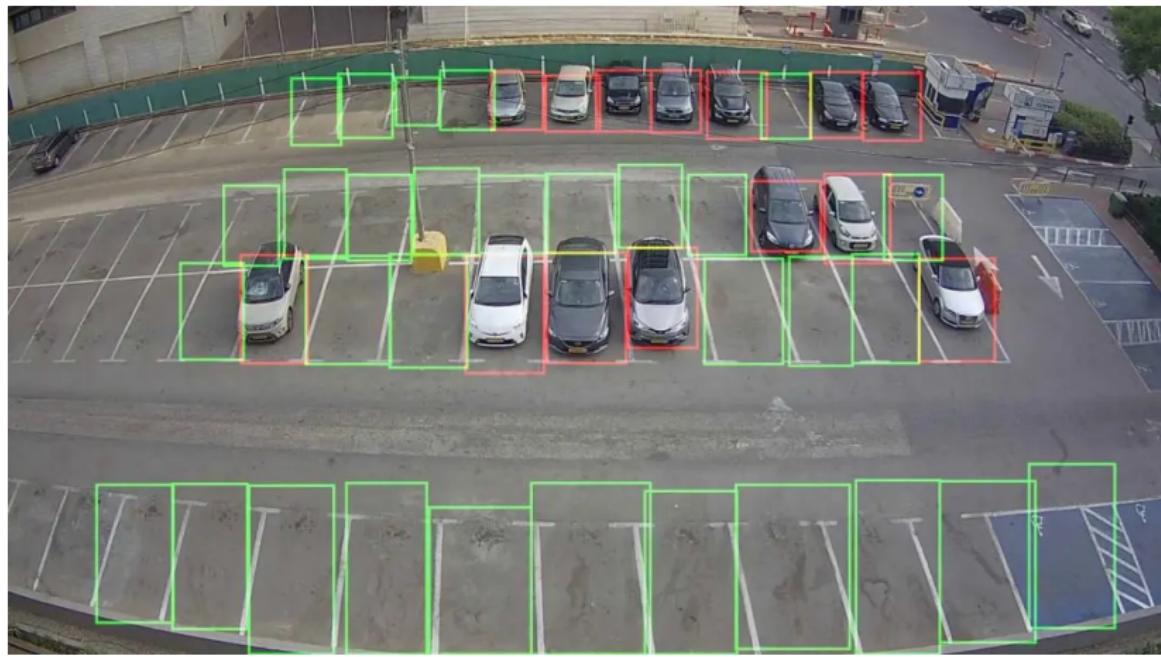
Aplicações



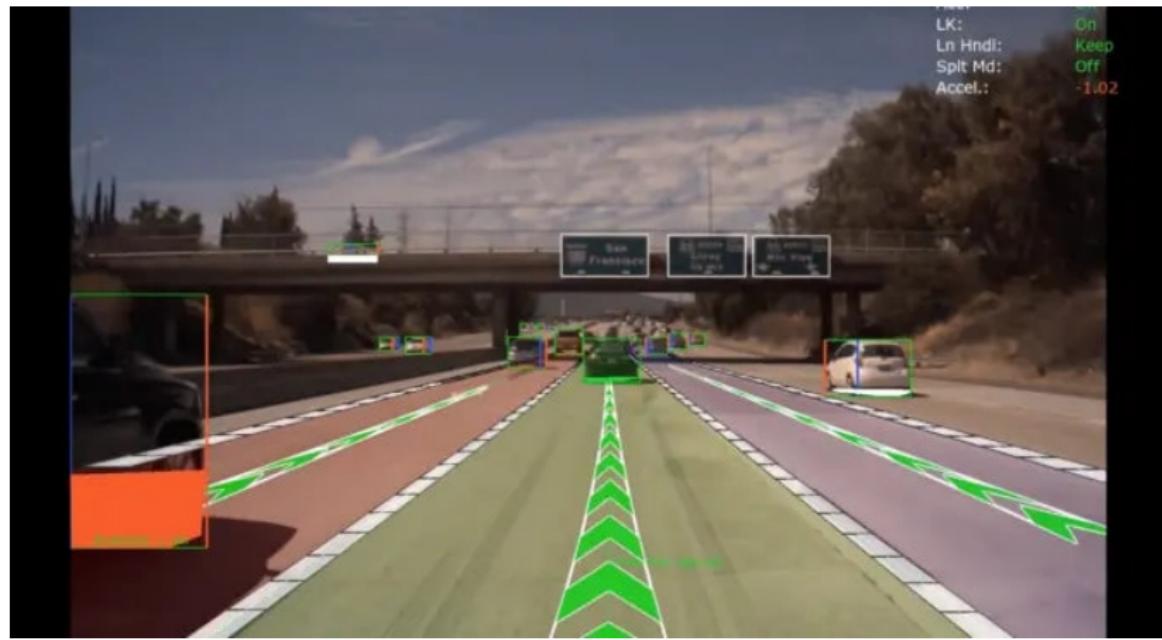
Aplicações



Aplicações



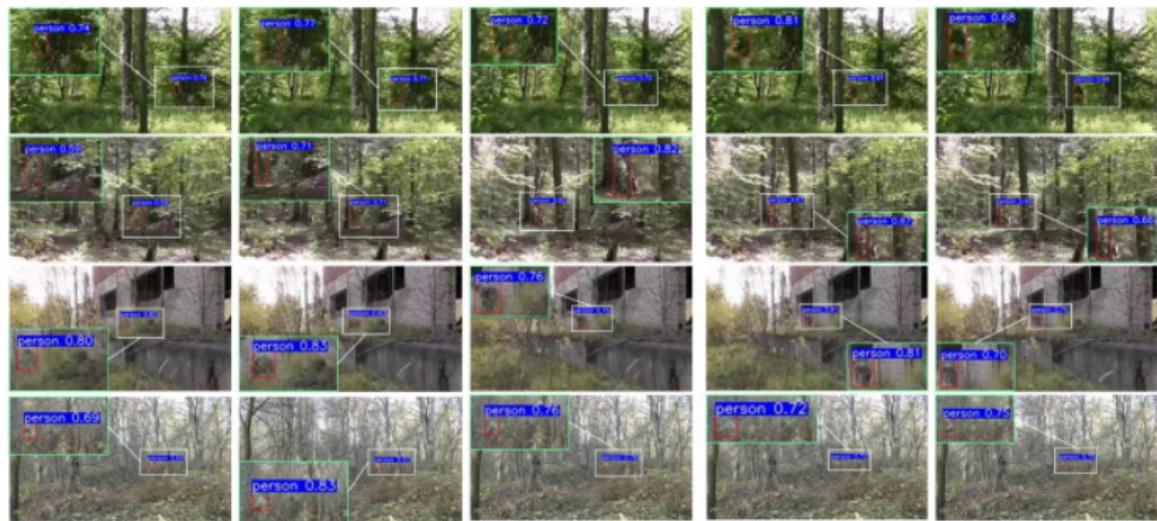
Aplicações



Aplicações



Aplicações



Aplicações



Aplicações



Sumário

- 1 Introdução
- 2 Trajetória acadêmica
- 3 Visão Computacional
- 4 Redes Neurais Convolucionais
 - Aplicações
- 5 Yolo
 - Aplicações
- 6 Outras Aplicações
- 7 Considerações Finais

Considerações Finais

- Minha formação em matemática e estatística forneceu a base necessária para avançar em visão computacional, com o apoio de programas como PIBID e PIBIC.
- A visão computacional tem impactado positivamente diversas áreas.
- A validação é fundamental. Somente após validar com métricas como precisão, recall e IoU, podemos garantir que os modelos são confiáveis em situações reais.

Considerações Finais

- A matemática abre um vasto leque de oportunidades. Aproveitem o aprendizado teórico para explorar aplicações. A combinação de matemática, estatística e IA cria uma base sólida para inovação.
- Cada imagem processada e cada dado analisado representam uma oportunidade de transformar desafios complexos em soluções inovadoras que impactam vidas. Continuar aprendendo nos permite não apenas acompanhar as mudanças, mas também liderar o caminho para novos avanços.

Obrigado!

Dúvidas ou perguntas?

Contato:

- Email: fernando.humberto@ufba.br
- LinkedIn: <https://www.linkedin.com/in/fernandomoraesds/>

Sinta-se à vontade para entrar em contato!